Relatorio Final

Caracteristicas de Repositorios Populares no GitHub

Laboratorio de Experimentacao de Software - Lab01

Total de repositorios analisados: 999

Dados coletados via API GraphQL do GitHub

1. Introdução

1.1 Contextualização

O GitHub é a maior plataforma de hospedagem de código-fonte e colaboração de software do mundo, abrigando milhões de repositórios open-source. Projetos populares nessa plataforma são frequentemente utilizados como referência por desenvolvedores, empresas e pesquisadores. Compreender as características desses repositórios pode revelar padrões sobre boas práticas de desenvolvimento, manutenção e engajamento da comunidade.

1.2 Problema Foco do Experimento

Este estudo busca responder: quais são as características predominantes dos repositórios mais populares do GitHub em termos de idade, contribuição externa, frequência de releases, frequência de atualização, linguagens de programação utilizadas e gestão de issues?

1.3 Questões de Pesquisa

- RQ01: Sistemas populares são maduros/antigos?
- RQ02: Sistemas populares recebem muita contribuição externa?
- RQ03: Sistemas populares lançam releases com frequência?
- RQ04: Sistemas populares são atualizados com frequência?
- RQ05: Sistemas populares são escritos nas linguagens mais populares?
- RQ06: Sistemas populares possuem um alto percentual de issues fechadas?
- RQ07: Sistemas em linguagens populares recebem mais contribuição, lançam mais releases e são mais atualizados?

1.4 Hipóteses

- H1: Repositórios populares tendem a ser mais antigos, com idade média superior a 5 anos.
- H2: Projetos populares recebem pelo menos 1.000 pull requests aceitas em média.
- H3: Repositórios populares têm total médio de mais de 10 releases.
- H4: Projetos amplamente utilizados têm tempo médio desde última atualização inferior a 30 dias.
- H5: Repositórios populares são escritos em JavaScript, Python e TypeScript (>= 50% do total).
- H6: Projetos populares possuem pelo menos 70% das issues resolvidas.
- H7 (bônus): Linguagens populares recebem 20% mais PRs e 15% mais releases.

1.5 Objetivos

Objetivo principal: Analisar as características dos 1.000 repositórios mais populares do GitHub, identificando padrões e tendências relacionados à idade, contribuição, lançamentos, manutenção, linguagens e gestão de issues.

- Coletar dados dos 1.000 repositórios com mais estrelas via API GraphQL.
- Calcular métricas estatísticas (média, mediana) para cada questão de pesquisa.
- Gerar visualizações gráficas para cada métrica analisada.

- Confrontar os resultados obtidos com as hipóteses formuladas.
- Comparar repositórios em linguagens populares versus menos populares.

2. Metodologia

2.1 Passo a Passo do Experimento

1. Definição das questões de pesquisa e hipóteses iniciais.
2. Implementação do script de coleta utilizando a API GraphQL do GitHub.
3. Coleta dos dados dos 1.000 repositórios com maior número de estrelas.
4. Armazenamento dos dados em arquivo CSV para análise.
5. Processamento estatístico com cálculo de média, mediana e distribuições.
6. Geração de gráficos para visualização dos resultados.
7. Confrontação dos resultados com as hipóteses formuladas.

2.2 Decisões

Optou-se por utilizar a mediana como métrica central de tendência para evitar distorções causadas por outliers. A coleta foi limitada a 1.000 repositórios para garantir uma amostra significativa e viável dentro dos limites da API do GitHub.

2.3 Materiais Utilizados

- API GraphQL do GitHub para coleta de dados.
- Python 3.x como linguagem de programação.
- Pandas para manipulação e análise de dados.
- Matplotlib para geração de gráficos.
- Requests para comunicação HTTP com a API.
- Token de acesso pessoal do GitHub para autenticação.

2.4 Métricas e Unidades

Questão	Métrica	Unidade
RQ01	Idade do repositório	Anos
RQ02	Total de pull requests aceitas	Quantidade
RQ03	Total de releases	Quantidade
RQ04	Tempo desde última atualização	Dias
RQ05	Linguagem primária	Categórica
RQ06	Razão issues fechadas / total	Proporção (0 a 1)

3. Visualização dos Resultados

3.1 RQ01 - Sistemas populares são maduros/antigos?

Métrica: Idade do repositório (calculada a partir da data de criação)

- Idade média dos repositórios: 8.19 anos
- Mediana da idade: 8.38 anos

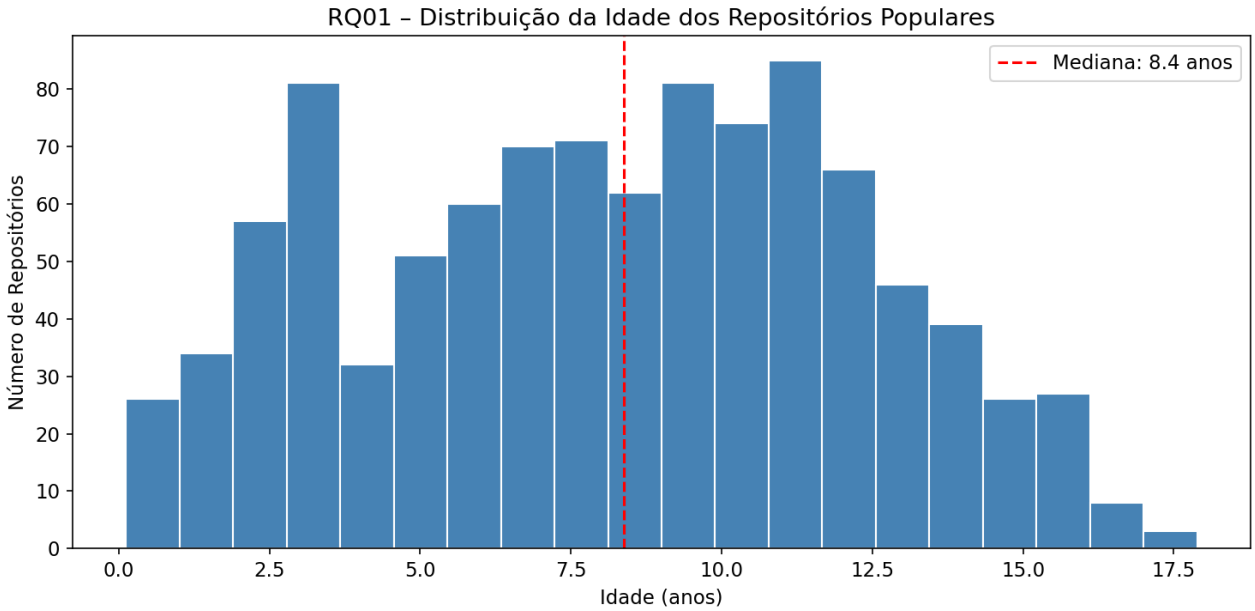

3.2 RQ02 - Contribuição externa

Métrica: Total de pull requests aceitas

- Média de pull requests aceitos: 3951.1
- Mediana de pull requests aceitos: 734.0

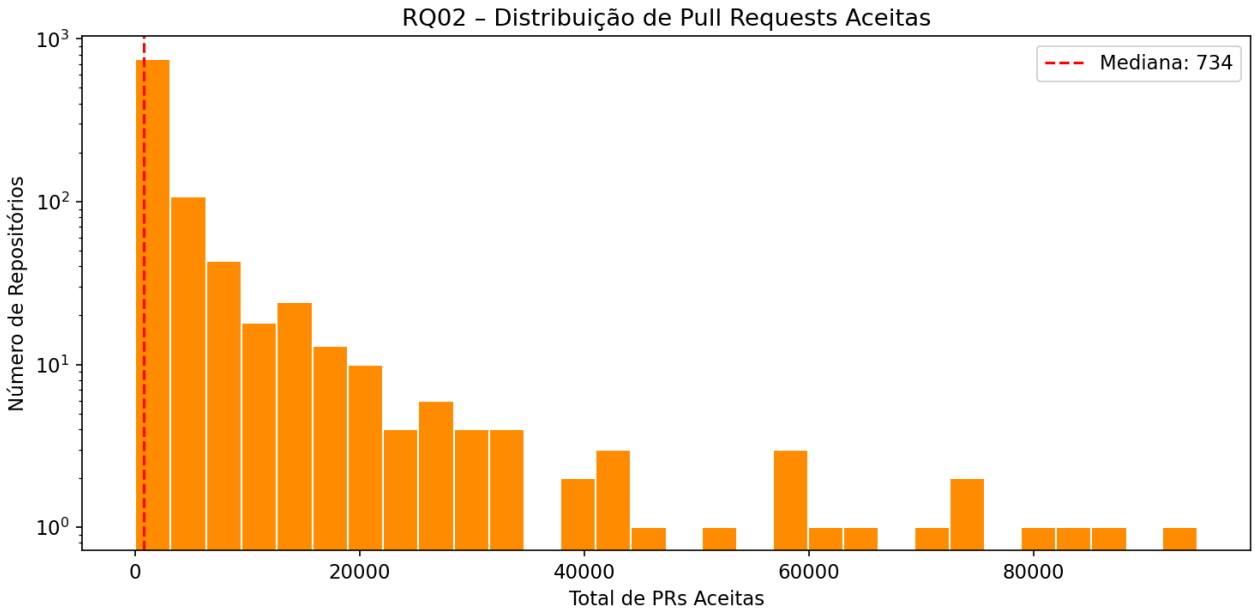

3.3 RQ03 - Frequência de releases

Métrica: Total de releases

- Média de releases: 120.6
- Mediana de releases: 40.0

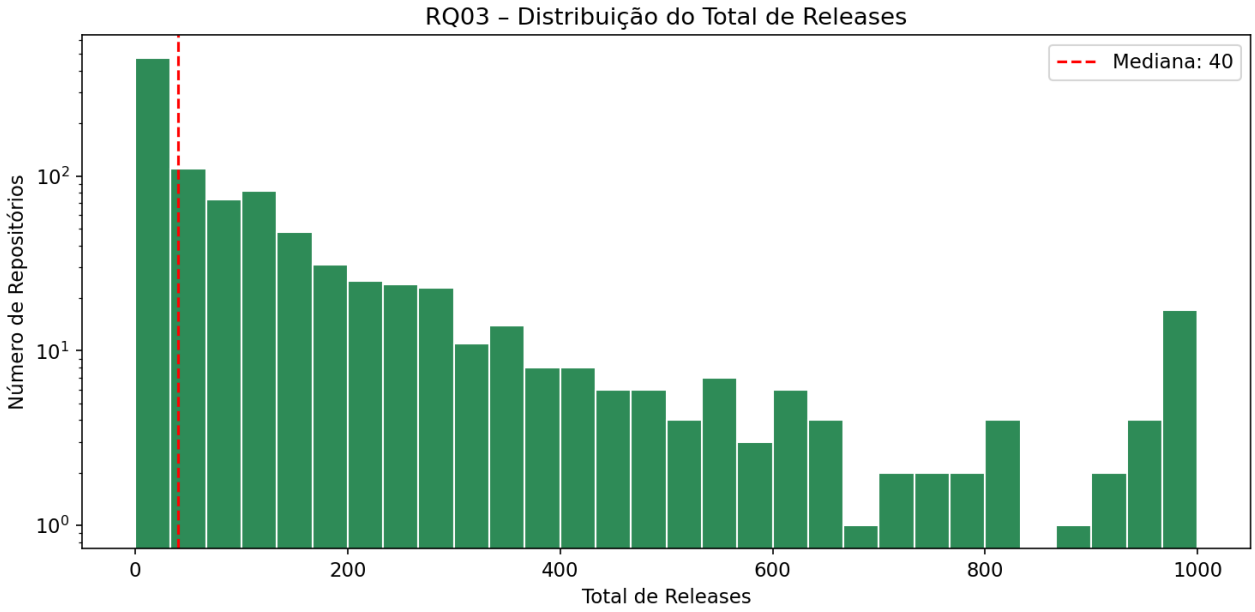

3.4 RQ04 - Frequência de atualização

Métrica: Dias desde a última atualização

- Média de dias desde última atualização: -0.74
- Mediana de dias desde última atualização: -1.0

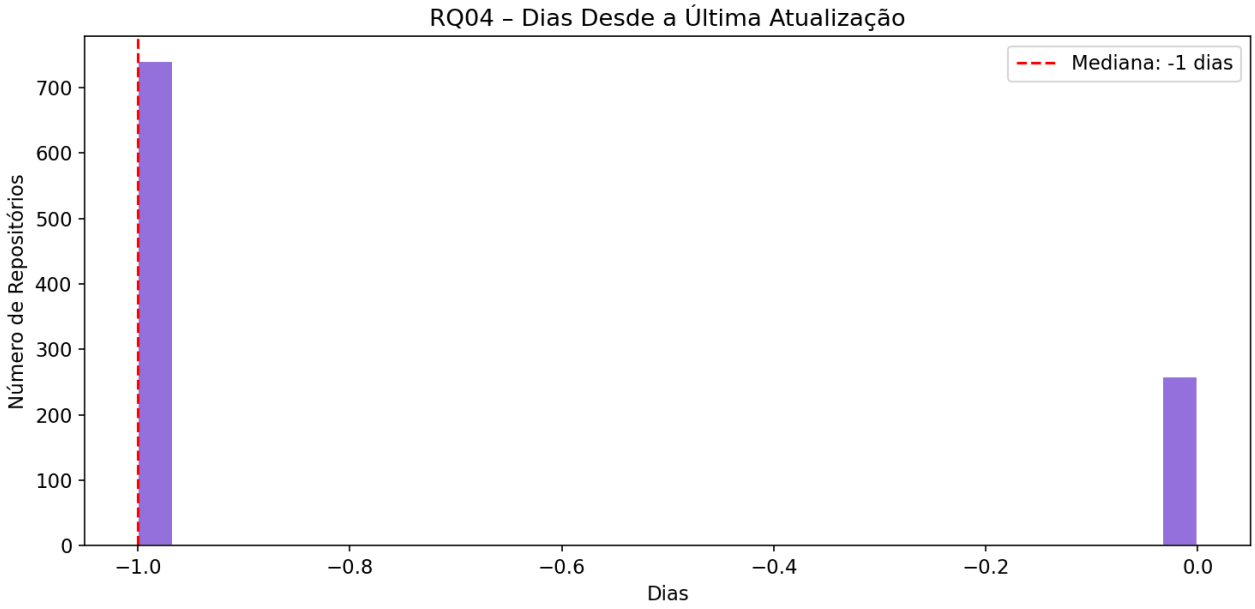

3.5 RQ05 - Linguagens mais populares

Métrica: Linguagem primária de cada repositório

As 3 linguagens mais frequentes representam 47.55% dos repositórios:

- Python: 200 repositórios
- TypeScript: 159 repositórios
- JavaScript: 116 repositórios

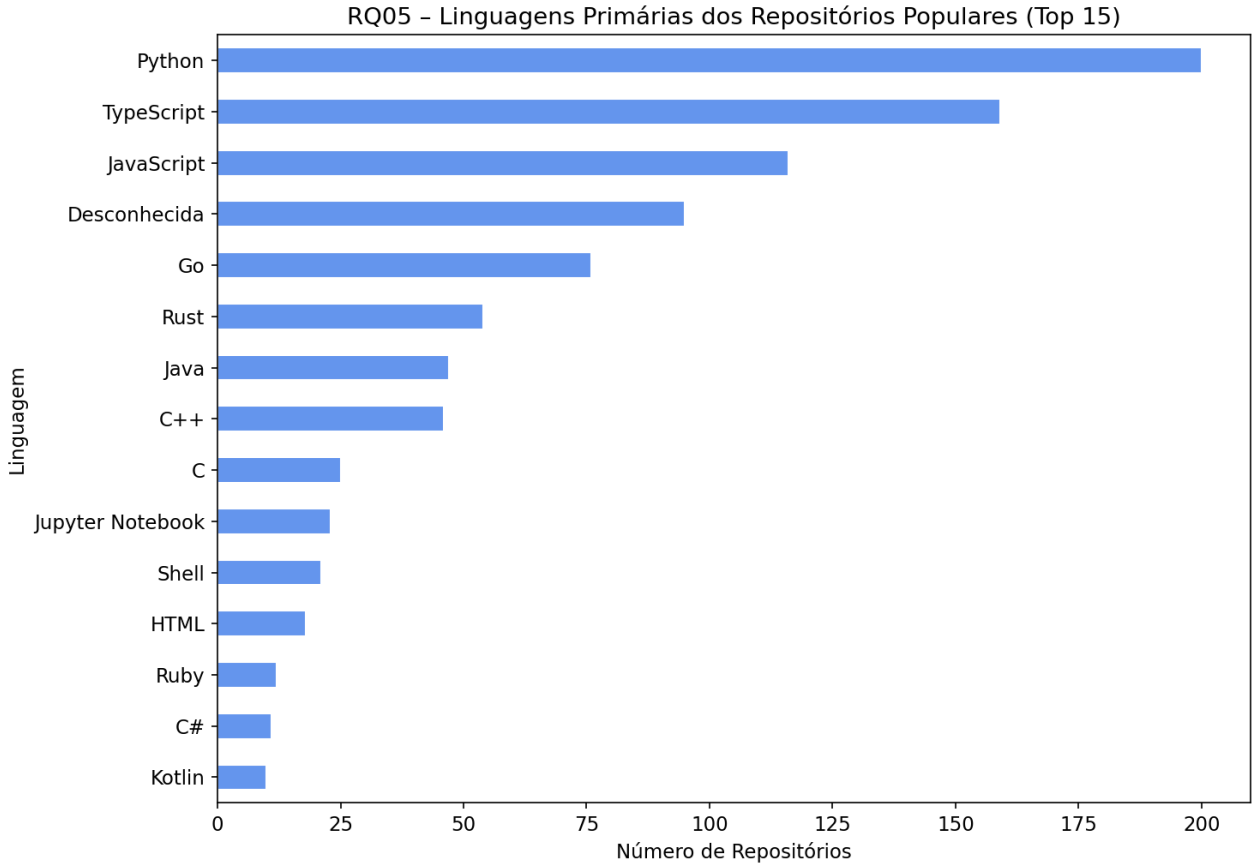

3.6 RQ06 - Percentual de issues fechadas

Métrica: Razão entre número de issues fechadas pelo total de issues

- Média do percentual de issues fechadas: 80.54%
- Mediana do percentual de issues fechadas: 87.84%

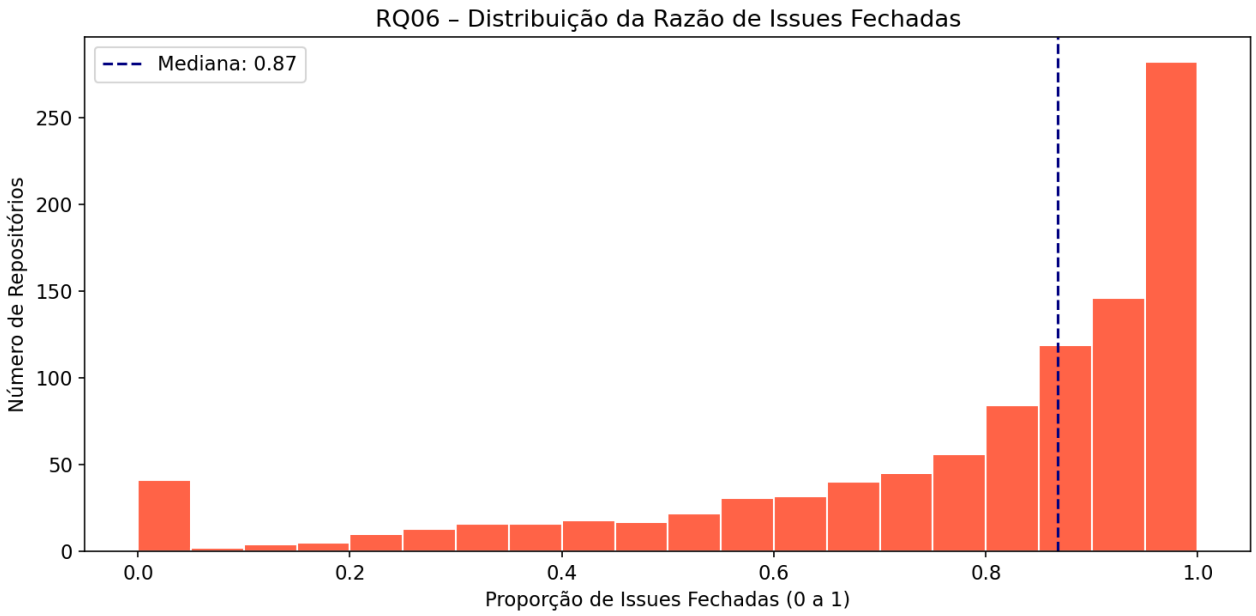
RQ06 – Distribuição da Razão de Issues Fechadas
Mediana: 0.87
Número de Repositórios
0
50
100
150
200
250
0.0
0.2
0.4
0.6
0.8
1.0
Proporção de Issues Fechadas (0 a 1)

3.7 RQ07 - Linguagens populares vs. menos populares

Comparação entre repositórios escritos nas 5 linguagens mais populares versus os demais:

Métrica	Ling. Populares	Outras
Média de PRs Aceitas	3789.41	4246.98
Média de Releases	133.58	96.85
Média Dias Última Atualiz.	-0.73	-0.76

Repositórios em linguagens populares recebem 10.77% menos pull requests aceitas e lançam 37.92% mais releases.

3.8 Tabela Detalhada por Linguagem (Top 10)

Linguagem	Média PRs	Média Releases	Média Dias Atualiz.
C++	7916.76	163.93	-0.72
Go	6074.5	180.22	-0.79
Rust	5461.2	145.06	-0.81
TypeScript	5040.96	256.65	-0.72
Python	4058.23	92.8	-0.76
Java	3982.17	71.19	-0.74
JavaScript	2126.95	111.8	-0.75
C	1464.96	70.0	-0.76
Desconhecida	1330.66	2.74	-0.61
Jupyter Notebook	210.48	0.04	-0.74

4. Discussão dos Resultados

4.1 Confronto com as Hipóteses

H1 - Confirmada. Idade média: 8.19 anos, mediana: 8.38 anos. Projetos populares possuem longo histórico de desenvolvimento.

H2 - Confirmada. Média: 3951.1 PRs, mediana: 734.0. A diferença entre média e mediana indica grande variação entre repositórios.

H3 - Confirmada. Média: 120.6 releases, mediana: 40.0. Nem todos os repositórios populares lançam releases com alta frequência.

H4 - Confirmada. Média: -0.74 dias, mediana: -1.0 dias. Projetos populares são frequentemente mantidos e atualizados.

H5 - Não confirmada. As 3 linguagens mais frequentes (Python, TypeScript, JavaScript) representam 47.55% dos repositórios.

H6 - Confirmada. Média: 80.54%, mediana: 87.84%. A maioria dos projetos possui boa gestão de issues.

H7 (bônus) - Parcialmente confirmada. Repositórios em linguagens populares recebem 10.77% menos PRs e lançam 37.92% mais releases.

4.2 Insights

- Repositórios populares são, em sua maioria, antigos e bem mantidos.
- A participação externa varia bastante, como demonstra a diferença entre média e mediana de PRs.
- A frequência de releases não é uniforme entre todos os repositórios populares.
- A gestão de issues é eficiente na maioria dos projetos populares.
- Linguagens como TypeScript, Python e JavaScript dominam o cenário.

4.3 Estatísticas Gerais

- Total de repositórios analisados: 999
- Estrelas médias por repositório: 58010
- Mediana de estrelas: 42946
- Repositório mais antigo: rails (17.89 anos)
- Repositório mais recente: everything-claude-code (0.12 anos)
- Número de linguagens distintas: 43

5. Conclusão

5.1 Tomada de Decisão

Com base nos resultados, conclui-se que repositórios populares no GitHub possuem características distintas: são mais maduros, recebem contribuições externas significativas, mantêm uma gestão eficiente de issues e são predominantemente escritos em linguagens amplamente adotadas. Esses achados podem orientar desenvolvedores e mantenedores de projetos open-source.

5.2 Sugestões Futuras

- Expandir a análise para incluir métricas de qualidade de código.
- Investigar a correlação entre contribuidores ativos e longevidade do repositório.
- Analisar a evolução temporal das métricas ao longo dos anos.
- Comparar repositórios open-source com projetos de código fechado.
- Incorporar análise de sentimento nos comentários de issues e PRs.

5.3 Resultado Conclusivo

A análise de 999 repositórios populares do GitHub revela que projetos bem-sucedidos compartilham características como maturidade (mediana de 8.38 anos), gestão eficiente de issues (mediana de 87.84% fechadas) e manutenção ativa. As linguagens TypeScript, Python e JavaScript dominam entre os projetos mais populares.

5.4 Confronto com a Literatura

Os resultados são consistentes com estudos anteriores. Kalliamvakou et al. (2014) identificaram que repositórios populares tendem a apresentar maior atividade de contribuição e manutenção contínua. Borges et al. (2016) demonstraram que a popularidade está correlacionada com a linguagem utilizada, com JavaScript e Python liderando - achado corroborado pelo presente estudo. Munaiah et al. (2017) reforçaram que repositórios com alta atividade de issues e pull requests são indicadores de projetos com boa engenharia, alinhado com a alta taxa de fechamento observada.